

ЗАНЯТИЕ 1.2

# ЛИНЕЙНЫЙ КЛАССИФИКАТОР И ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ



**Артур Сапрыкин**

---

# ЦЕЛИ ЗАНЯТИЯ

---

## В КОНЦЕ ЗАНЯТИЯ ВЫ:

- будете знать преимущества и недостатки линейных моделей, а также требования к данным;
- научитесь реализовывать алгоритм градиентного спуска и логистическую регрессию;
- повторите понятие условной вероятности.

---

О ЧЁМ ПОГОВОРИМ И ЧТО  
СДЕЛАЕМ

- 
1. Линейные модели: требования к данным и практика;
  2. Логистическая регрессия: практическое задание;
  3. Градиентный спуск: теория и практическое задание;
  4. Немного про условную вероятность.



ЛИНЕЙНЫЕ

МОДЕЛИ

# ПРИЧИНЫ ПОПУЛЯРНОСТИ

- Линейные модели подходят для описания многих процессов
- Относительная простота вычислений и интерпретации результатов
- Вклад нескольких факторов часто можно разбить на сумму влияния каждого фактора в отдельности




## ПРИМЕРЫ ИСПОЛЬЗОВАНИЯ

- Прогноз продаж по объему инвентаря, загрузке, площади и другим «линейным» характеристикам
- Построение вероятностных моделей в страховании, кредитном скоринге, инвестиционных проектах
- Предсказание цены товара на основании его характеристик
- Построение трендов

---

ОПРЕДЕЛЕНИЕ И КОД

# ОПРЕДЕЛЕНИЕ



$$y_i = \sum_{j=1}^m w_j X_{ij} + e_i$$

$Y$  – целевая переменная


$W$  – вектор весов модели

$X$  – матрица наблюдений

$e$  – ошибка модели

# ПРИМЕР ИЗ КОДА

## LINEAR REGRESSION.IPYTHON





---


# ПОСТРОЕНИЕ ЛИНЕЙНОЙ МОДЕЛИ



# КАК СТРОИМ ЛИНЕЙНУЮ МОДЕЛЬ




# МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ



Как можно получить эту  
прямую?

$p(y \mid x, \alpha)$  – вероятность получить  
 $y$  при входных данных  $x$ .  $\alpha$  –  
параметр модели

# МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ



Как можно получить эту прямую?

$p(y \mid x, \alpha)$  – вероятность получить  $y$  при входных данных  $x$ .  $\alpha$  – параметр модели

**Введем**

**функцию:**

$$W(\alpha) = \prod_i p(x_i, \alpha)$$

# МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

**Функция максимального  
правдоподобия:**

$$L(\alpha) = \sum_i \log p(x_i, \alpha)$$

# МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

**Функция максимального  
правдоподобия:**

$$L(\alpha) = \sum_i \log p(x_i, \alpha)$$

Как подобрать значение  $\alpha$ , чтобы максимизировать  $L(\alpha)$ ?

Необходимо минимизировать среднеквадратичную ошибку между прогнозными и фактическими значениями



# ДОКАЗАТЕЛЬСТВО

<https://habrahabr.ru/company/ods/blog/323890/#metod-maksimalnogo-pravdopodobiya>



МАНХЭТТЕНСКОЕ РАССТОЯНИЕ



# ВРЕМЯ КОДА

REGRESSION\_CARS.IPYNB

---

# ПРАКТИЧЕСКОЕ ЗАДАНИЕ 1

МАНХЭТТЕНСКОЕ РАССТОЯНИЕ



ВРЕМЯ ПРАКТИКИ

SAT\_MODEL.IPYNB

---

# ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ



# ПРОГНОЗ ВЕРОЯТНОСТИ


Прогнозирует вероятность отнесения наблюдения к определенному классу

Модель:  $L = a_0 + a_1X_1 + a_2X_2 + \dots + a_nX_n$

# ПРОГНОЗ ВЕРОЯТНОСТИ

Вероятность:

$$p = \frac{1}{1 + e^{-L}}$$



МАНХЭТТЕНСКОЕ РАССТОЯНИЕ

СНОВА ПРАКТИКА

LOGISTIC\_REGRESSION\_ATHLETES\_CLASSIFIER.IPYNB

---

# ПРАКТИЧЕСКОЕ ЗАДАНИЕ 2

МАНХЭТТЕНСКОЕ РАССТОЯНИЕ



УЛУЧШАЕМ ТОЧНОСТЬ МОДЕЛИ

С НОВЫМИ ПРИЗНАКАМИ




---

# ГРАДИЕНТНЫЙ СПУСК


# ПРОИЗВОДНАЯ И МИНИМУМ

Производная определяет скорость изменения функции в точке



# ПРОИЗВОДНАЯ И МИНИМУМ


Производная определяет скорость изменения функции в точке



$$F'(X_0) = \lim_{\Delta X \rightarrow 0} \frac{\Delta Y}{\Delta X}$$

# ИЩЕМ МИНИМУМ


Допустим, необходимо  
найти минимум суммы  
среднеквадратичной  
ошибки для  
параметров модели



# ИЩЕМ МИНИМУМ


Возьмем произвольную точку на графике и будем пошагово «спускаться» к минимуму

$$x_{i+1} = x_i - \alpha \nabla F(x_i)$$




# ВОЗМОЖНЫЕ ПРОБЛЕМЫ

Шаг слишком большой




# ВОЗМОЖНЫЕ ПРОБЛЕМЫ

Шаг слишком большой




Остаемся в локальном минимуме



# ВАРИАНТЫ ВЫБОРА $\lambda$


- Постоянной – метод может расходиться
- С дробным шагом – делим на число каждый шаг
- С наискорейшим спуском –  $\alpha$  выбирается так, чтобы следующая итерация была точкой минимума функции  $f$  на луче





ГРАДИЕНТНЫЙ СПУСК

# ПРИМЕР В 3D



МАНХЭТТЕНСКОЕ РАССТОЯНИЕ



РЕАЛИЗУЕМ

GRADIENT\_DESCENT.IPYNB

---

ЕСЛИ КЛАССОВ БОЛЬШЕ ДВУХ

МАНХЭТТЕНСКОЕ РАССТОЯНИЕ



# ПРИМЕР

IRIS\_DATASET.IPYNB


---

ДЛЯ КАКИХ ДАННЫХ  
ЭТО РАБОТАЕТ?


# ТРЕБОВАНИЯ К ДАННЫМ

- Линейная зависимость целевой переменной
- Нормальное распределение остатков
- Постоянная изменчивость остатков


# ТРЕБОВАНИЯ К ДАННЫМ




Линейная  
взаимосвязь  $X$  и  $Y$



# ТРЕБОВАНИЯ К ДАННЫМ




Линейная  
взаимосвязь  $X$  и  $Y$








# НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ ОСТАТКОВ

[HTTPS:// GALLERY.SHINYAPPS.IO/SLR\\_DIAG/](https://gallery.shinyapps.io/slr_diag/)



# НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ ОСТАТКОВ


[HTTPS:// GALLERY.SHINYAPPS.IO/SLR\\_DIAG/](https://gallery.shinyapps.io/slr_diag/)



# ГОМОСКЕДАСТИЧНОСТЬ

Постоянная изменчивость остатков

Пример гетероскедастичной последовательности








# ГОМОСКЕДАСТИЧНОСТЬ

Постоянная изменчивость остатков

Пример гетероскедастичной последовательности




—

SVM

# Множество гиперплоскостей

- Множество решений для  $a, b, c$ .
- SVM находит оптимальную разделяющую поверхность
- Максимизирует «зазор»

Граница:  
 $ax + by - c = 0$




# Максимальный зазор

- $w$  – нормаль к разделяющей плоскости
- $x_i$  - sample
- $y_i$  - класс sample  $i$  (+1 or -1) (важно, не 1 и 0)
- Классификатор:  $f(x_i) = \text{sign}(w^T x_i + b)$

- Зазор для точки  $x$  
$$r = y \frac{w^T x + b}{\|w\|}$$

- Зазор всего датасета – минимум зазора для всех точек



# Формула

- Итого получаем задачу оптимизации:

Найти  $\mathbf{w}$  и  $b$  такие что  
максимально; и для всех  $\{(\mathbf{x}_i, y_i)\}$   
 $\mathbf{w}^T \mathbf{x}_i + b \geq 1$  если  $y_i = 1$ ;  $\mathbf{w}^T \mathbf{x}_i + b \leq -1$  если  $y_i = -1$


- Перепишем в более понятном виде

Найти  $\mathbf{w}$  и  $b$  такие что  
 $\Phi(\mathbf{w}) = 0.5 \mathbf{w}^T \mathbf{w}$  максимально  
И для всех  $\{(\mathbf{x}_i, y_i)\}$ :  $y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$



# Non-linear SVMs


- Линейно разделимые датасеты хорошо классифицируются



- Но что делать, если они не линейно разделимы?



- Можно попробовать отобразить данные в пр-во более высокой размерности



# The “Kernel Trick”

- SVM зависит от скалярного произведения  $K(x_i, x_j) = x_i^T x_j$
- Если каждая точка отображается в пр-во более высокой размерности при помощи  $\Phi: x \rightarrow \phi(x)$ , тогда скалярное произведение становится:
- $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$
- Функция ядра – это функция соотв. Скалярному произведению в пр-ве более высокой размерности

# Kernels

- Примеры
- Линейное
- Полиноминое  $K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^T \mathbf{z})^d$
- RBF

$$K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma^2}$$

---

ЧТО МЫ СЕГОДНЯ УЗНАЛИ

## ЧТО МЫ СЕГОДНЯ УЗНАЛИ

---

1. Вспомнили основы теории вероятностей.
2. Изучили линейные модели и требования к ним на основе функции правдоподобия.
3. Реализовали логистическую регрессию.
4. Изучили алгоритм градиентного спуска и потренировались в его реализации.

---

ПОЛЕЗНЫЕ МАТЕРИАЛЫ

1. Статья о линейных моделях в ODS  
<https://habrahabr.ru/company/ods/blog/323890/>
2. Курс «Основы статистики» на Stepik.org  
<https://stepik.org/course/Основы-статистики-76>



Спасибо  
за внимание!

Артур Сапрыкин